


TUGAS 3

**LOGISTIC REGRESSION, K-NEAREST NEIGHBORS, SUPPORT VECTOR MACHINE,
NAIVE BAYES, DAN DECISION TREE**

disusun untuk memenuhi
tugas mata kuliah Pembelajaran Mesin A

oleh :

Sadinal Mufti	(2208107010007)
M. Agradika Ridhal Eljatin	(2208107010020)
Jihan Nabilah	(2208107010035)
Firjatullah Afny Abus	(2208107010059)
Athar Rayyan Muhammad	(2208107010074)



DEPARTEMEN INFORMATIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS SYIAH KUALA

TAHUN 2025

1. Pendahuluan

1.1. Latar Belakang

Dalam era modern, penggunaan teknik machine learning dalam bidang kesehatan semakin berkembang pesat, terutama dalam upaya prediksi dan klasifikasi risiko penyakit. Salah satu aplikasi penting adalah prediksi risiko kematian pada pasien yang mengalami gagal jantung. Dengan banyaknya variabel klinis yang tersedia, dibutuhkan metode yang efektif untuk membangun model prediksi yang akurat.

Dalam tugas ini, digunakan dataset *Heart Failure Clinical Records* yang memuat informasi tentang berbagai indikator medis pasien gagal jantung, seperti usia, tekanan darah, kadar serum kreatinin, dan fraksi ejeksi jantung. Dataset ini memungkinkan pengembangan model klasifikasi yang dapat membantu mengidentifikasi pasien berisiko tinggi secara dini.

Dengan menerapkan berbagai algoritma machine learning seperti Logistic Regression, K-Nearest Neighbors (K-NN), Naive Bayes, dan Decision Tree, diharapkan dapat diperoleh model yang mampu memprediksi outcome pasien secara efektif. Evaluasi model dilakukan menggunakan metrik evaluasi standar seperti confusion matrix, akurasi, precision, recall, dan F1-score untuk membandingkan performa masing-masing algoritma.

1.2. Tujuan Tugas

- Memahami dan mengeksplorasi dataset klinis yang berkaitan dengan gagal jantung.
- Melakukan pra-pemrosesan data untuk memastikan kualitas data yang baik sebelum digunakan dalam pembangunan model.
- Membangun model klasifikasi menggunakan empat algoritma berbeda, yaitu Logistic Regression, K-Nearest Neighbors (K-NN), Naive Bayes, dan Decision Tree.
- Mengevaluasi performa model berdasarkan metrik evaluasi klasifikasi untuk menentukan model terbaik.
- Menganalisis hasil prediksi dan menarik kesimpulan terkait efektivitas masing-masing algoritma dalam memprediksi risiko kematian pasien.

2. Deskripsi Data

2.1. Informasi Dataset

- Nama Dataset: Heart Failure Clinical Records Dataset
- Sumber: [Heart Failure Clinical Records - UCI Machine Learning Repository](#)
- Deskripsi Singkat: Dataset ini berisi catatan medis pasien yang menderita gagal jantung. Data dikumpulkan untuk menganalisis faktor-faktor klinis yang berhubungan dengan kematian akibat gagal jantung, dan banyak digunakan dalam penelitian machine learning serta studi prediksi kesehatan. Dataset ini mencakup fitur-fitur klinis seperti usia, tekanan darah, kadar enzim, dan status kesehatan lainnya.

2.2. Struktur Dataset

- Jumlah Sampel: 299 Pasien
- Jumlah Fitur: 13 Kolom
- Label: Kolom DEATH_EVENT (0 = pasien bertahan hidup, 1 = pasien meninggal)
- Format Data: CSV (Comma-Separated Values)
- Deskripsi Kolom:
 - **age**: Usia pasien dalam tahun.
 - **anaemia**: Kondisi anemia (0 = Tidak, 1 = Ya).
 - **high_blood_pressure**: Riwayat tekanan darah tinggi (0 = Tidak, 1 = Ya).
 - **creatinine_phosphokinase**: Level enzim CPK dalam darah (mcg/L).
 - **diabetes**: Riwayat diabetes (0 = Tidak, 1 = Ya).
 - **ejection_fraction**: Persentase darah yang dipompa keluar oleh jantung setiap detakan (%).
 - **platelets**: Jumlah platelet dalam darah (kiloplatelets/mL).
 - **serum_creatinine**: Level kreatinin serum dalam darah (mg/dL).
 - **serum_sodium**: Level natrium serum dalam darah (mEq/L).
 - **sex**: Jenis kelamin pasien (0 = Perempuan, 1 = Laki-laki).
 - **smoking**: Status merokok pasien (0 = Tidak, 1 = Ya).
 - **time**: Lama tindak lanjut dalam hari.
 - **DEATH_EVENT**: Status kematian pasien selama masa tindak lanjut (0 = Hidup, 1 = Meninggal).


3. Pemahaman Dataset

3.1. Distribusi Data

--- Deskripsi Statistik ---								
	count	mean	std	min	25%	50%	75%	max
age	299.0	60.833893	11.894809	40.0	51.0	60.0	70.0	95.0
anaemia	299.0	0.431438	0.496107	0.0	0.0	0.0	1.0	1.0
creatinine_phosphokinase	299.0	581.839465	970.287881	23.0	116.5	250.0	582.0	7861.0
diabetes	299.0	0.418060	0.494067	0.0	0.0	0.0	1.0	1.0
ejection_fraction	299.0	38.083612	11.834841	14.0	30.0	38.0	45.0	80.0
high_blood_pressure	299.0	0.351171	0.478136	0.0	0.0	0.0	1.0	1.0
platelets	299.0	263358.029264	97804.236869	25100.0	212500.0	262000.0	303500.0	850000.0
serum_creatinine	299.0	1.393880	1.034510	0.5	0.9	1.1	1.4	9.4
serum_sodium	299.0	136.625418	4.412477	113.0	134.0	137.0	140.0	148.0
sex	299.0	0.648829	0.478136	0.0	0.0	1.0	1.0	1.0
smoking	299.0	0.321070	0.467670	0.0	0.0	0.0	1.0	1.0
time	299.0	130.260870	77.614208	4.0	73.0	115.0	203.0	285.0
DEATH_EVENT	299.0	0.321070	0.467670	0.0	0.0	0.0	1.0	1.0

Gambar 1. Distribusi Data

Setiap fitur dianalisis berdasarkan jumlah data (count), rata-rata (mean), standar deviasi (std), nilai minimum (min), kuartil pertama (25%), median (50%), kuartil ketiga (75%), dan nilai maksimum (max). Rata-rata usia pasien adalah sekitar 60.83 tahun, dengan usia termuda 40 tahun dan tertua 95 tahun. Sebagian besar fitur biner seperti anaemia, diabetes, high_blood_pressure, sex, dan smoking memiliki rata-rata di bawah 0.5, menunjukkan bahwa mayoritas pasien tidak mengalami kondisi tersebut. Rata-rata ejection_fraction, yang mengukur persentase darah yang dipompa keluar dari jantung setiap detak, adalah 38.08%, lebih rendah dari normal, menandakan adanya banyak kasus gagal jantung. Nilai creatinine_phosphokinase dan platelets menunjukkan penyebaran nilai yang cukup besar, terlihat dari tingginya standar deviasi. Selain itu, rata-rata kadar serum_creatinine (1.39) dan serum_sodium (136.62) juga tercatat, memberikan gambaran tentang kondisi fungsi ginjal dan keseimbangan elektrolit pasien. Terakhir, DEATH_EVENT memiliki rata-rata 0.32, yang mengindikasikan sekitar 32% pasien dalam dataset ini meninggal dalam periode observasi. Statistik ini memberikan pemahaman awal tentang distribusi dan variasi data, serta membantu mengarahkan fokus dalam analisis lanjutan.




Gambar 2. Visualisasi Distribusi Target

Nilai 0 menunjukkan pasien yang tidak mengalami kematian selama masa observasi, sedangkan nilai 1 menunjukkan pasien yang meninggal dunia. Dari total 299 pasien, sebanyak 203 pasien (sekitar 67,89%) tidak mengalami kematian, sedangkan 96 pasien (sekitar 32,11%) mengalami kematian. Distribusi ini mengindikasikan adanya ketidakseimbangan kelas, dengan


jumlah pasien yang bertahan hidup lebih banyak dibandingkan yang meninggal. Ketidakseimbangan seperti ini perlu diperhatikan dalam tahapan pemodelan, karena dapat mempengaruhi performa model klasifikasi.

3.2. Analisis Fitur



Gambar 3. Visualisasi Fitur Kategori

Analisis fitur kategorik dilakukan untuk memahami distribusi setiap kategori dalam dataset. Fitur anaemia menunjukkan bahwa sebagian besar pasien tidak mengalami anemia, sedangkan sebagian kecil mengalami anemia. Untuk fitur diabetes, proporsi antara pasien yang memiliki diabetes dan yang tidak cukup berimbang, walaupun lebih banyak pasien yang tidak memiliki diabetes. Fitur high_blood_pressure memperlihatkan bahwa sebagian besar pasien tidak menderita tekanan darah tinggi. Pada fitur sex, pasien laki-laki mendominasi jumlah pasien dalam dataset ini dibandingkan dengan pasien perempuan. Terakhir, fitur smoking menunjukkan bahwa sebagian besar pasien bukan perokok, dengan proporsi perokok lebih sedikit.




Gambar 4. Analisis Fitur numerik

Analisis terhadap fitur numerik menunjukkan gambaran umum mengenai karakteristik pasien dalam dataset. Fitur age memiliki rentang usia pasien dari 40 hingga 95 tahun dengan rata-rata sekitar 60 tahun, menunjukkan bahwa mayoritas pasien berada di usia lanjut. Pada fitur creatinine_phosphokinase, terdapat nilai minimum 23 hingga maksimum 7861, dengan rata-rata sekitar 582, mengindikasikan adanya pasien dengan level CPK yang sangat tinggi yang mungkin menunjukkan kerusakan otot serius. Fitur ejection_fraction memiliki rata-rata sekitar 38%, dengan nilai minimum 14% dan maksimum 80%; nilai ejection fraction yang rendah biasanya mengindikasikan fungsi jantung yang buruk.

Jumlah platelets (trombosit) pasien sangat bervariasi, dengan nilai minimum 25.100 dan maksimum 850.000, serta rata-rata sekitar 263.358, yang mencerminkan adanya variasi kesehatan darah yang cukup besar di antara pasien. Pada fitur serum_creatinine, nilai rata-rata 1,39 menunjukkan adanya beberapa pasien dengan tingkat kreatinin tinggi, yang bisa menjadi indikator adanya masalah fungsi ginjal. Kadar serum_sodium relatif stabil dengan rata-rata sekitar 136,6, tetapi terdapat variasi kecil yang bisa mempengaruhi kesehatan kardiovaskular. Terakhir, time mewakili lamanya pengamatan pasien, dengan rata-rata sekitar 130 hari, menunjukkan sebagian besar pasien dipantau selama beberapa bulan.

3.3. Analisis Korelasi



Gambar 5. Visualisasi Heatmap Korelasi

Heatmap korelasi yang dihasilkan menunjukkan hubungan antar fitur dalam dataset. Nilai korelasi berkisar dari -1 hingga 1, di mana nilai positif mendekati 1 menunjukkan hubungan linier positif yang kuat, nilai negatif mendekati -1 menunjukkan hubungan linier negatif yang kuat, dan nilai mendekati 0 berarti tidak ada hubungan linier yang jelas.

Dari heatmap, dapat dilihat bahwa fitur `ejection_fraction` memiliki korelasi negatif yang cukup kuat terhadap `DEATH_EVENT`, artinya semakin rendah persentase ejection fraction (fungsi pemompaan jantung), semakin besar kemungkinan terjadinya kematian. Sementara itu, `serum_creatinine` memperlihatkan korelasi positif terhadap `DEATH_EVENT`, menunjukkan bahwa semakin tinggi kadar kreatinin dalam darah, risiko kematian pasien juga meningkat.

Fitur lain seperti `age`, `serum_sodium`, dan `time` juga memiliki korelasi yang terlihat terhadap `DEATH_EVENT`, walaupun nilainya lebih rendah dibanding `ejection_fraction` dan `serum_creatinine`. Misalnya, `time` memiliki korelasi negatif, menunjukkan bahwa semakin lama waktu observasi, kemungkinan kematian cenderung lebih kecil.


Di antara fitur-fitur lainnya, sebagian besar tidak menunjukkan korelasi yang sangat kuat satu sama lain, mengindikasikan bahwa setiap fitur dapat membawa informasi yang cukup unik dan tidak terlalu redundant.

Melalui analisis korelasi ini, fitur-fitur yang memiliki hubungan kuat terhadap target (DEATH_EVENT) dapat diprioritaskan dalam proses modeling atau pengembangan prediksi lebih lanjut.

3.4. Analisis Outliers

```
--- Analisis Outliers ---
age: 0 outliers (0.00%)
creatinine_phosphokinase: 29 outliers (9.70%)
ejection_fraction: 2 outliers (0.67%)
platelets: 21 outliers (7.02%)
serum_creatinine: 29 outliers (9.70%)
serum_sodium: 4 outliers (1.34%)
time: 0 outliers (0.00%)
```

Gambar 6. Hasil Analisis Outliers



Gambar 7. Visualisasi Outliers dari Fitur Numerik

Hasil analisis menunjukkan bahwa tidak ditemukan outlier pada fitur age dan time, menandakan distribusi yang stabil. Fitur creatinine_phosphokinase dan serum_creatinine memiliki jumlah outlier tertinggi (masing-masing 9,70%), mengindikasikan adanya nilai ekstrem terkait kerusakan otot dan fungsi ginjal. Outlier juga ditemukan pada platelets (7,02%), ejection_fraction (0,67%), dan serum_sodium (1,34%). Keberadaan outlier ini penting untuk diperhatikan karena dapat mempengaruhi performa model prediksi. Oleh karena itu, langkah pengelolaan seperti transformasi atau penyesuaian outlier perlu dipertimbangkan sesuai kebutuhan analisis.

4. Eksplorasi Data dan Pra-pemrosesan

4.1. Deteksi dan Penanganan Missing Values

```
--- Cek Nilai Hilang ---
age                                0
anaemia                            0
creatinine_phosphokinase          0
diabetes                           0
ejection_fraction                 0
high_blood_pressure               0
platelets                         0
serum_creatinine                  0
serum_sodium                      0
sex                               0
smoking                           0
time                             0
DEATH_EVENT                       0
dtype: int64
Tidak ada nilai yang hilang dalam dataset.
```


Gambar 8. Hasil Deteksi Missing Values

Pemeriksaan terhadap seluruh kolom dalam dataset menunjukkan bahwa tidak terdapat nilai yang hilang (missing values) pada data. Setiap fitur memiliki jumlah entri yang lengkap sebanyak 299 sampel, sehingga tidak diperlukan proses imputasi atau penghapusan data akibat nilai yang kosong. Kondisi ini memudahkan proses analisis dan pemodelan selanjutnya karena kualitas data dari sisi kelengkapan sudah baik.

4.2. Penanganan Outliers

Setelah proses identifikasi outlier pada fitur numerik, dilakukan penanganan menggunakan metode capping (winsorization). Metode ini membatasi nilai-nilai ekstrem pada data dengan menggantinya ke nilai ambang batas tertentu, yaitu nilai kuartil ke-1 ($Q1$) - $1.5 \times IQR$ sebagai batas bawah dan kuartil ke-3 ($Q3$) + $1.5 \times IQR$ sebagai batas atas.

Capping diterapkan pada fitur yang memiliki outlier signifikan, seperti creatinine_phosphokinase, platelets, serum_creatinine, serum_sodium, dan ejection_fraction. Dengan metode ini, outlier tidak dihapus dari dataset, melainkan disesuaikan ke batas maksimum dan minimum yang ditentukan. Tujuan utama dari pendekatan ini adalah untuk mengurangi pengaruh nilai ekstrem tanpa menghilangkan data, sehingga model dapat belajar dengan lebih stabil dan akurat. Langkah ini efektif menjaga keseimbangan distribusi data dan meningkatkan kinerja algoritma pembelajaran mesin yang sensitif terhadap outlier.



Gambar 9. Visualisasi Outliers setelah Ditangani

Setelah proses capping (winsorization) diterapkan pada fitur-fitur numerik yang mengandung outlier, dilakukan visualisasi ulang menggunakan boxplot untuk melihat perubahan distribusi data. Hasil visualisasi menunjukkan bahwa nilai-nilai ekstrem yang sebelumnya berada jauh di luar batas kini telah berada dalam rentang yang wajar.

Sebagian besar boxplot kini terlihat lebih simetris dan tidak lagi memiliki titik-titik outlier di luar whisker. Hal ini menandakan bahwa proses winsorization berhasil mengurangi pengaruh nilai ekstrem tanpa menghilangkan data. Distribusi data yang lebih bersih ini diharapkan dapat meningkatkan stabilitas dan akurasi model dalam proses pelatihan.

4.3. Normalisasi/Standardisasi Data

Standardisasi dilakukan untuk memastikan bahwa setiap fitur numerik memiliki rata-rata (mean) sebesar 0 dan standar deviasi sebesar 1. Ini penting terutama ketika menggunakan algoritma machine learning yang sensitif terhadap skala data, seperti regresi logistik, SVM, dan KNN.

Dalam proses ini:

Digunakan StandardScaler dari pustaka sklearn.preprocessing.

Fitur numerik pada data training (X_{train}) digunakan untuk menghitung rata-rata dan standar deviasi, kemudian diterapkan transformasi pada data training dan testing.

Hasil transformasi dikembalikan ke bentuk DataFrame agar lebih mudah dianalisis dan digunakan kembali.

```

Standardisasi fitur numerik...
5 sampel data training setelah standardisasi:
  age  anaemia  creatinine_phosphokinase  diabetes  ejection_fraction  \
0 -0.269050  1.110696                -0.085829 -0.900337           0.176528
1 -0.706883 -0.900337                -0.944468  1.110696           1.847425
2  1.219579 -0.900337                0.377887 -0.900337          -1.494369
3  0.256348 -0.900337                -0.740637 -0.900337          -1.076645
4 -1.407414 -0.900337                0.377887 -0.900337          -1.494369

  high_blood_pressure  platelets  serum_creatinine  serum_sodium  sex  \
0          -0.770281   -1.176330          -0.518252    0.559915 -1.333818
1          -0.770281    1.347665          -0.975140   -0.345802  0.749728
2           1.298227    0.073295           1.537743   -1.477949  0.749728
3          -0.770281   -0.161783           2.108853   -0.345802  0.749728
4           1.298227   -1.646486           0.852412   -0.345802  0.749728

  smoking  time
0 -0.682831 -0.467847
1 -0.682831 -1.359167
2 -0.682831 -1.591685
3 -0.682831  1.121028
4 -0.682831  0.681827

```

Gambar 10. Standarisasi Fitur Numerik

Contoh hasil standardisasi menunjukkan bahwa setiap nilai dalam kolom sudah dalam skala yang seragam, memusatkan data di sekitar nol dan memperkecil potensi dominasi fitur tertentu karena skala yang lebih besar.

4.4. Pembagian Data Train-Test

Dataset dibagi menjadi dua bagian, yaitu 80% untuk data latih (training data) dan 20% untuk data uji (testing data) guna melatih dan menguji performa model.

5. Implementasi dan Evaluasi Model

Pada tugas ini, kami membangun dan membandingkan beberapa model machine learning untuk mengevaluasi kinerjanya. Tujuannya adalah untuk memilih model yang paling sesuai dan efektif dalam memprediksi risiko kematian pada pasien gagal jantung. Berikut adalah model-model yang digunakan:

5.1. Logistic Regression

Model pertama yang digunakan adalah Logistic Regression, yaitu model klasifikasi yang umum digunakan untuk memprediksi probabilitas kejadian suatu peristiwa biner, dalam hal ini apakah pasien meninggal (1) atau tidak (0). Model ini bekerja dengan menghitung probabilitas dari suatu kelas berdasarkan kombinasi linier dari fitur-fitur input.

Untuk meningkatkan performa model, dilakukan pencarian parameter terbaik menggunakan GridSearchCV dengan validasi silang sebanyak 5 kali lipat (5-fold cross-validation). Parameter yang ditelusuri meliputi:

- C: nilai regulasi (mengontrol overfitting)
- penalty: jenis penalti regulasi (l1 dan l2)
- solver: metode optimisasi (liblinear dan saga)

- max_iter: jumlah iterasi maksimal pelatihan

Hasil pencarian parameter terbaik:


- C = 1
- penalty = 'l1'
- solver = 'saga'
- max_iter = 1000

Classification Report:				
	precision	recall	f1-score	support
0	0.81	0.95	0.88	41
1	0.83	0.53	0.65	19
accuracy			0.82	60
macro avg	0.82	0.74	0.76	60
weighted avg	0.82	0.82	0.80	60

Gambar 11. Classification Report Model Logistic Regression

Hasil evaluasi model pada data uji:

- Accuracy: 81.67%
- Precision: 83.33%
- Recall: 52.63%
- F1-score: 64.52%



Gambar 12. Feature Importance Model Logistic Regression

Interpretasi:

Model memiliki presisi yang baik dalam memprediksi pasien yang meninggal, namun recall masih cukup rendah, artinya masih ada kasus kematian yang tidak terdeteksi oleh model.

Grafik Feature Importance menunjukkan fitur-fitur yang paling berpengaruh terhadap prediksi model, yang paling berpengaruh adalah fitur time dan serum_creatine berdasarkan koefisien absolut dari Logistic Regression.

5.2. K-Nearest Neighbors

Model kedua yang digunakan adalah K-Nearest Neighbors (KNN), sebuah algoritma klasifikasi berbasis instance-based learning. KNN bekerja dengan cara mencari sejumlah tetangga terdekat dari data uji pada data latih, kemudian menentukan kelas berdasarkan mayoritas tetangga tersebut.

Untuk mendapatkan performa terbaik, dilakukan pencarian parameter menggunakan GridSearchCV dengan 5-fold cross-validation. Parameter yang ditelusuri meliputi:

- `n_neighbors`: jumlah tetangga terdekat yang digunakan (1 sampai 30, ganjil)
- `weights`: pembobotan tetangga (uniform untuk bobot sama, distance untuk bobot berdasarkan jarak)
- `metric`: jenis metrik jarak (euclidean, manhattan, minkowski)
- `algorithm`: algoritma pencarian tetangga (auto, ball_tree, kd_tree, brute)

Parameter terbaik yang diperoleh:

- `n_neighbors = 5`
- `weights = 'uniform'`
- `metric = 'euclidean'`
- `algorithm = 'auto'`

Classification Report:				
	precision	recall	f1-score	support
0	0.74	0.90	0.81	41
1	0.60	0.32	0.41	19
accuracy			0.72	60
macro avg	0.67	0.61	0.61	60
weighted avg	0.70	0.72	0.69	60

Gambar 13. Classification Report Model KNN

Hasil evaluasi model pada data uji:

- Accuracy: 71.67%
- Precision: 60.00%
- Recall: 31.58%
- F1-score: 41.38%

Interpretasi:

Model cukup baik dalam mengenali kasus negatif (pasien yang tidak meninggal), namun kinerjanya cukup lemah dalam mendeteksi pasien yang meninggal, ditunjukkan oleh nilai recall yang rendah (sekitar 31.6%).

Meskipun akurasi terlihat lumayan (71.67%), F1-score untuk kelas positif cukup rendah, yang menjadi pertimbangan penting jika fokus utama adalah mendeteksi pasien yang berisiko meninggal.

5.3. Support Vector Machine


Model ketiga yang digunakan adalah Support Vector Machine (SVM), sebuah algoritma klasifikasi yang bekerja dengan mencari hyperplane terbaik yang memisahkan kelas-kelas dalam data. SVM sangat efektif dalam ruang berdimensi tinggi dan tetap efisien meskipun jumlah fitur melebihi jumlah sampel.

Untuk memperoleh performa terbaik, dilakukan tuning hyperparameter menggunakan GridSearchCV dengan 5-fold cross-validation. Parameter yang diuji meliputi:

- C: parameter regulasi (0.1, 1, 10, 100)
- gamma: koefisien kernel untuk rbf, poly, dan sigmoid (scale, auto, 0.1, 0.01, 0.001)
- kernel: jenis kernel yang digunakan (linear, rbf, poly, sigmoid)

Parameter terbaik yang diperoleh:

- C = 10
- gamma = 'scale'
- kernel = 'linear'

A screenshot of a terminal window showing a classification report for an SVM model. The report is displayed in a dark-themed font. It includes precision, recall, f1-score, and support for two classes (0 and 1), as well as overall accuracy, macro average, and weighted average.

Classification Report:				
	precision	recall	f1-score	support
0	0.81	0.95	0.88	41
1	0.83	0.53	0.65	19
accuracy			0.82	60
macro avg	0.82	0.74	0.76	60
weighted avg	0.82	0.82	0.80	60

Gambar 14. Classification Report Model SVM

Hasil evaluasi model pada data uji:

- Accuracy: 81.67%
- Precision: 83.33%
- Recall: 52.63%
- F1-score: 64.52%

Interpretasi:

- SVM menunjukkan performa yang mirip dengan Logistic Regression, baik dari sisi akurasi maupun F1-score.
- Model mampu mengenali kelas positif (pasien meninggal) lebih baik dibanding KNN, meskipun recall belum terlalu tinggi.
- Cocok digunakan ketika data bersifat linier atau hampir linier, seperti yang terlihat dari pemilihan kernel linear sebagai yang terbaik.

5.4. Naive Bayes

Model keempat yang digunakan adalah Naive Bayes, tepatnya varian Gaussian Naive Bayes, yang mengasumsikan bahwa setiap fitur mengikuti distribusi normal (Gaussian). Algoritma ini dikenal dengan pendekatannya yang sederhana namun cukup efektif, terutama untuk data dengan dimensi tinggi atau ketika waktu pelatihan perlu sangat cepat.

Naive Bayes bekerja berdasarkan prinsip teorema Bayes, dengan asumsi bahwa antar fitur bersifat saling bebas (naive assumption). Meskipun asumsi ini sering kali tidak realistis, model ini tetap dapat memberikan hasil yang kompetitif dalam banyak kasus klasifikasi.

Classification Report:				
	precision	recall	f1-score	support
0	0.80	0.90	0.85	41
1	0.71	0.53	0.61	19
accuracy			0.78	60
macro avg	0.76	0.71	0.73	60
weighted avg	0.78	0.78	0.77	60

Gambar 15. Classification Report Model Naive Bayes

Hasil evaluasi model pada data uji:

- Accuracy: 78.33%
- Precision: 71.43%
- Recall: 52.63%
- F1-score: 60.61%

Interpretasi:

Naive Bayes menghasilkan performa yang cukup baik, meskipun sedikit di bawah Logistic Regression dan SVM dalam hal akurasi dan F1-score.

Recall sebesar 52.63% menunjukkan kemampuan model yang lumayan dalam mendeteksi kelas positif (pasien meninggal), walaupun masih bisa ditingkatkan.

Keunggulan utama model ini adalah kecepatan pelatihan dan sederhana, cocok jika membutuhkan solusi cepat tanpa banyak tuning parameter.

5.5. Desicion Tree


Model kelima yang digunakan adalah Decision Tree, sebuah algoritma pembelajaran yang sangat intuitif dan mudah diinterpretasikan. Decision Tree membagi data berdasarkan fitur-fitur yang paling informatif melalui proses pemilihan atribut yang memaksimalkan information gain (dalam hal ini menggunakan kriteria entropy sebagai hasil dari tuning).

Model ini dioptimasi menggunakan teknik Grid Search dengan kombinasi parameter seperti:

- max_depth: kedalaman maksimum pohon
- min_samples_split: jumlah minimum sampel untuk memisahkan node
- min_samples_leaf: jumlah minimum sampel dalam daun pohon
- criterion: metode pengukuran kualitas split (gini atau entropy)
- max_features: jumlah fitur maksimum yang dipertimbangkan saat membuat split (sqrt, log2, atau semua fitur)

Hasil terbaik diperoleh dengan:

- criterion='entropy'
- max_depth=5
- min_samples_leaf=4
- min_samples_split=2
- max_features='sqrt'




Classification Report:				
	precision	recall	f1-score	support
0	0.80	0.90	0.85	41
1	0.71	0.53	0.61	19
accuracy			0.78	60
macro avg	0.76	0.71	0.73	60
weighted avg	0.78	0.78	0.77	60

Gambar 16. Classification Report Model Desicion Tree

Hasil evaluasi model pada data uji:

- Accuracy: 78.33%
- Precision: 71.43%
- Recall: 52.63%
- F1-score: 60.61%



Gambar 17. Feature Importance Model Desicion Tree

Berdasarkan hasil Feature Importance pada model Decision Tree, fitur-fitur yang paling berpengaruh terhadap prediksi adalah serum_creatine dan time, diikuti oleh age.


- serum_creatine memiliki kontribusi terbesar dalam pemisahan kelas, yang menunjukkan bahwa kadar kreatinin serum adalah faktor kunci dalam memprediksi hasil.
- time juga memainkan peran penting, yang mungkin berkaitan dengan durasi atau waktu yang relevan dalam konteks pengambilan data.
- age menunjukkan pengaruh moderat, yang mengindikasikan bahwa usia juga berperan dalam prediksi, meskipun tidak sepenting serum_creatine dan time.

6. Analisis Hasil

6.1. Logistic Regression sebagai Model Terbaik:


Berdasarkan evaluasi model, Logistic Regression menunjukkan kinerja terbaik dengan Accuracy 0.8167 dan F1-Score 0.6452. Ini berarti bahwa model mampu memprediksi dengan baik dan memiliki keseimbangan yang baik antara Precision dan Recall, meskipun masih ada ruang untuk perbaikan.

Faktor risiko yang paling berpengaruh menurut model ini adalah time (periode tindak lanjut), ejection_fraction (fraksi ejeksi), serum_creatinine (kadar kreatinin serum), age (usia), dan sex (jenis kelamin). Faktor-faktor ini adalah indikator utama dalam menentukan kemungkinan kematian pasien akibat gagal jantung.



Gambar 18. Visualisasi Perbandingan Model

6.2. Faktor Risiko Paling Berpengaruh:



Gambar 19. Visualisasi Feature Importance

- Time: Pasien yang bertahan hidup memiliki waktu tindak lanjut yang lebih panjang dibandingkan dengan yang meninggal. Oleh karena itu, penting untuk memonitor periode tindak lanjut dan memastikan bahwa pasien yang memiliki waktu tindak lanjut lebih pendek mendapatkan perhatian medis lebih intensif.
- Ejection Fraction: Nilai yang lebih rendah menunjukkan risiko yang lebih tinggi, sehingga pasien dengan fraksi ejeksi rendah harus mendapatkan perhatian lebih dalam hal manajemen dan intervensi medis.
- Serum Creatinine: Pasien dengan kadar kreatinin serum yang lebih tinggi cenderung memiliki risiko kematian yang lebih tinggi, yang

menunjukkan pentingnya pemantauan fungsi ginjal sebagai bagian dari manajemen gagal jantung.

- Age: Usia yang lebih tua meningkatkan risiko kematian, dan oleh karena itu usia harus menjadi faktor pertimbangan penting dalam pengelolaan pasien.
- Sex: Jenis kelamin juga berperan dalam tingkat kematian, dengan jenis kelamin laki-laki cenderung menunjukkan risiko yang lebih tinggi. Hal ini dapat menjadi indikasi adanya perbedaan biologis atau faktor terkait gaya hidup.

7. Kesimpulan

Model prediksi gagal jantung yang menggunakan Logistic Regression berhasil memberikan hasil yang baik, dengan accuracy mencapai 81,67% dan F1-Score 0,6452, menunjukkan kemampuan yang solid dalam memprediksi risiko kematian pasien. Faktor-faktor yang paling berpengaruh dalam model ini adalah time (periode tindak lanjut), ejection_fraction (fraksi ejeksi), serum_creatinine (kadar kreatinin serum), age (usia), dan sex (jenis kelamin), yang semuanya memberikan wawasan penting dalam manajemen pasien. Pasien dengan waktu tindak lanjut lebih pendek, fraksi ejeksi rendah, kadar kreatinin serum tinggi, dan usia yang lebih tua memiliki risiko kematian lebih tinggi. Oleh karena itu, pemantauan lebih ketat pada pasien dengan faktor risiko tinggi sangat dianjurkan. Meskipun model ini memberikan hasil yang menjanjikan, keterbatasan seperti ukuran dataset yang kecil dan potensi hubungan non-linear yang kompleks tetap perlu diperhatikan. Untuk pengembangan lebih lanjut, pengumpulan data lebih banyak dan penambahan fitur klinis lainnya bisa meningkatkan akurasi model, serta memungkinkan penerapan sistem peringatan dini yang lebih efektif untuk pasien berisiko tinggi.