



UNIVERSITAS
SYIAH KUALA

LOGISTIC REGRESSION, K-NEAREST NEIGHBORS, SUPPORT VECTOR MACHINE, NAIVE BAYES, DAN DECISION TREE

Kelompok 5

SADINAL MUFTI (2208107010007)

M. AGRADIKA RIDHAL ELJATIN (2208107010020)

JIHAN NABILAH (2208107010035)

FIRJATULLAH AFNY ABUS (2208107010059)

ATHAR RAYYAN MUHAMMAD (2208107010074)



Latar Belakang

Dalam era modern, penerapan machine learning di bidang kesehatan berkembang pesat, khususnya untuk prediksi dan klasifikasi risiko penyakit. Salah satu aplikasinya adalah prediksi risiko kematian pada pasien gagal jantung. Dataset Heart Failure Clinical Records menyediakan berbagai indikator medis seperti usia, tekanan darah, serum kreatinin, dan fraksi ejeksi jantung, yang dapat digunakan untuk membangun model klasifikasi risiko. Berbagai algoritma seperti Logistic Regression, K-Nearest Neighbors, Naive Bayes, dan Decision Tree diterapkan untuk memprediksi outcome pasien, dengan evaluasi menggunakan confusion matrix, akurasi, precision, recall, dan F1-score guna membandingkan performa model.

Deskripsi Dataset

Nama: Heart Failure Clinical Records Dataset

Sumber: UCI Machine Learning Repository

Dataset ini memuat catatan medis pasien gagal jantung, mencakup fitur klinis seperti usia, tekanan darah, kadar enzim, dan faktor kesehatan lain. Data ini digunakan untuk menganalisis faktor risiko kematian dan banyak dimanfaatkan dalam penelitian machine learning di bidang kesehatan.

Struktur Dataset


- Sampel: 299 pasien
- Fitur: 13 kolom
- Label: DEATH_EVENT (0 = hidup, 1 = meninggal)
- Format: CSV
- Kolom utama:
- age (usia), anaemia, high_blood_pressure, creatinine_phosphokinase, diabetes, ejection_fraction, platelets, serum_creatinine, serum_sodium, sex, smoking, time, DEATH_EVENT.

Pemahaman Dataset


--- Deskripsi Statistik ---

	count	mean	std	min	25%	50%	75%	max
age	299.0	60.833893	11.894809	40.0	51.0	60.0	70.0	95.0
anaemia	299.0	0.431438	0.496107	0.0	0.0	0.0	1.0	1.0
creatinine_phosphokinase	299.0	581.839465	970.287881	23.0	116.5	250.0	582.0	7861.0
diabetes	299.0	0.418060	0.494067	0.0	0.0	0.0	1.0	1.0
ejection_fraction	299.0	38.083612	11.834841	14.0	30.0	38.0	45.0	80.0
high_blood_pressure	299.0	0.351171	0.478136	0.0	0.0	0.0	1.0	1.0
platelets	299.0	263358.029264	97804.236869	25100.0	212500.0	262000.0	303500.0	850000.0
serum_creatinine	299.0	1.393880	1.034510	0.5	0.9	1.1	1.4	9.4
serum_sodium	299.0	136.625418	4.412477	113.0	134.0	137.0	140.0	148.0
sex	299.0	0.648829	0.478136	0.0	0.0	1.0	1.0	1.0
smoking	299.0	0.321070	0.467670	0.0	0.0	0.0	1.0	1.0
time	299.0	130.260870	77.614208	4.0	73.0	115.0	203.0	285.0
DEATH_EVENT	299.0	0.321070	0.467670	0.0	0.0	0.0	1.0	1.0

Dataset dianalisis secara deskriptif. Usia rata-rata 60,8 tahun (40–95). Fitur biner <0,5, mayoritas tanpa kondisi tersebut. Ejection_fraction rata-rata 38%, menandakan gagal jantung umum. Creatinine_phosphokinase dan platelets punya sebaran luas. Serum_creatinine 1,39 dan serum_sodium 136,6. DEATH_EVENT 32% pasien meninggal. Statistik ini memberi gambaran awal data.



Analisis fitur kategorik menunjukkan mayoritas pasien tidak mengalami anemia, tekanan darah tinggi, atau merokok. Proporsi diabetes cukup berimbang, meski lebih banyak yang tidak diabetes. Pasien laki-laki mendominasi dataset.



Heatmap menunjukkan ejection_fraction (negatif) dan serum_creatinine (positif) paling kuat terkait DEATH_EVENT. Age, serum_sodium, dan time juga berpengaruh meski lebih lemah. Fitur lain cenderung lemah dan unik. Analisis ini memandu pemilihan fitur penting.




Eksplorasi Data dan Pra-pemrosesan

```
--- Cek Nilai Hilang ---
age          0
anaemia      0
creatinine_phosphokinase  0
diabetes     0
ejection_fraction  0
high_blood_pressure  0
platelets    0
serum_creatinine  0
serum_sodium  0
sex          0
smoking      0
time         0
DEATH_EVENT  0
dtype: int64
Tidak ada nilai yang hilang dalam dataset.
```

Gambar 8. Hasil Deteksi Missing Values

Dataset ini tidak memiliki nilai hilang; semua 299 sampel lengkap di setiap kolom. Dengan kelengkapan ini, analisis dan pemodelan dapat berjalan lancar tanpa perlu imputasi atau penghapusan data.



Gambar 9. Visualisasi Outliers setelah Ditangani

Setelah capping (winsorization) pada fitur numerik, boxplot menunjukkan distribusi lebih simetris tanpa outlier ekstrem. Proses ini berhasil meredam pengaruh nilai ekstrem tanpa menghapus data, sehingga diharapkan meningkatkan stabilitas dan akurasi model.

```
Standardisasi fitur numerik...
5 sampel data training setelah standardisasi:
age      anaemia  creatinine_phosphokinase  diabetes  ejection_fraction \
0 -0.269050  1.110696          -0.085829 -0.900337          0.176528
1 -0.706883 -0.900337          -0.944468  1.110696          1.847425
2  1.219579 -0.900337          0.377887 -0.900337          -1.494369
3  0.256348 -0.900337          -0.740637 -0.900337          -1.076645
4 -1.407414 -0.900337          0.377887 -0.900337          -1.494369

high_blood_pressure  platelets  serum_creatinine  serum_sodium  sex \
0 -0.770281 -1.176330          -0.518252  0.559915 -1.333818
1 -0.770281  1.347665          -0.975140 -0.345802  0.749728
2  1.298227  0.073295          1.537743 -1.477949  0.749728
3 -0.770281 -0.161783          2.108853 -0.345802  0.749728
4  1.298227 -1.646486          0.852412 -0.345802  0.749728

smoking  time
0 -0.682831 -0.467847
1 -0.682831 -1.359167
2 -0.682831 -1.591685
3 -0.682831  1.121028
4 -0.682831  0.681827
```

Gambar 10. Standarisasi Fitur Numerik

Standardisasi dilakukan agar setiap fitur numerik memiliki mean 0 dan standar deviasi 1, penting untuk algoritma seperti regresi logistik, SVM, dan KNN. Menggunakan StandardScaler dari sklearn, skala dihitung dari data training lalu diterapkan ke data training dan testing. Hasilnya dikembalikan ke DataFrame, memastikan semua fitur berskala seragam dan tidak ada yang mendominasi karena perbedaan skala.

Implementasi dan Evaluasi Model

01. Logistic Regression

Model ditingkatkan menggunakan GridSearchCV dengan 5-fold cross-validation untuk mencari kombinasi parameter terbaik, yaitu: C (regulasi), penalty (l1, l2), solver (liblinear, saga), dan max_iter. Hasil terbaik diperoleh pada C = 1, penalty = 'l1', solver = 'saga', dan max_iter = 1000.

Classification Report:

	precision	recall	f1-score	support
0	0.81	0.95	0.88	41
1	0.83	0.53	0.65	19
accuracy			0.82	60
macro avg	0.82	0.74	0.76	60
weighted avg	0.82	0.82	0.80	60

02. K-Nearest Neighbors

Untuk memperoleh performa terbaik, digunakan GridSearchCV dengan 5-fold cross-validation untuk menelusuri parameter: n_neighbors (1–30, ganjil), weights (uniform, distance), metric (euclidean, manhattan, minkowski), dan algorithm (auto, ball_tree, kd_tree, brute). Hasil terbaik diperoleh pada n_neighbors = 5, weights = 'uniform', metric = 'euclidean', dan algorithm = 'auto'

Classification Report:

	precision	recall	f1-score	support
0	0.74	0.90	0.81	41
1	0.60	0.32	0.41	19
accuracy			0.72	60
macro avg	0.67	0.61	0.61	60
weighted avg	0.70	0.72	0.69	60

Implementasi dan Evaluasi Model

03. Support Vector Machine

Untuk memperoleh performa terbaik, dilakukan tuning hyperparameter menggunakan GridSearchCV dengan 5-fold cross-validation terhadap parameter C (0.1, 1, 10, 100), gamma (scale, auto, 0.1, 0.01, 0.001), dan kernel (linear, rbf, poly, sigmoid). Hasil terbaik diperoleh pada C = 10, gamma = 'scale', dan kernel = 'linear'.

```
Classification Report:
              precision    recall  f1-score   support

     0           0.81         0.95         0.88         41
     1           0.83         0.53         0.65         19

 accuracy                   0.82         60
 macro avg                  0.82         60
 weighted avg              0.82         60
```

04. Naive Bayes

Naive Bayes bekerja berdasarkan prinsip teorema Bayes, dengan asumsi bahwa antar fitur bersifat saling bebas (naive assumption). Meskipun asumsi ini sering kali tidak realistis, model ini tetap dapat memberikan hasil yang kompetitif dalam banyak kasus klasifikasi.

```
Classification Report:
              precision    recall  f1-score   support

     0           0.80         0.90         0.85         41
     1           0.71         0.53         0.61         19

 accuracy                   0.78         60
 macro avg                  0.76         60
 weighted avg              0.78         60
```

Implementasi dan Evaluasi Model

05. Desicion Tree


Model dioptimasi menggunakan Grid Search dengan kombinasi parameter: `max_depth` (kedalaman maksimum pohon), `min_samples_split` (jumlah minimum sampel untuk memisahkan node), `min_samples_leaf` (jumlah minimum sampel pada daun), `criterion` (gini atau entropy), dan `max_features` (sqrt, log2, atau semua fitur). Hasil terbaik diperoleh pada `criterion = 'entropy'`, `max_depth = 5`, `min_samples_leaf = 4`, `min_samples_split = 2`, dan `max_features = 'sqrt'`.

```
Classification Report:
              precision    recall  f1-score   support

     0           0.80       0.90       0.85         41
     1           0.71       0.53       0.61         19

 accuracy              0.78         60
 macro avg           0.76       0.71       0.73         60
 weighted avg       0.78       0.78       0.77         60
```



Feature Importance Logistic Regression



Model memiliki presisi yang baik dalam memprediksi pasien yang meninggal, namun recall masih cukup rendah, artinya masih ada kasus kematian yang tidak terdeteksi oleh model.

Grafik Feature Importance menunjukkan fitur-fitur yang paling berpengaruh terhadap prediksi model, yang paling berpengaruh adalah fitur time dan serum_creatinine berdasarkan koefisien absolut dari Logistic Regression.

Feature Importance Decision Tree




Berdasarkan hasil Feature Importance pada model Decision Tree, fitur paling berpengaruh terhadap prediksi adalah serum_creatine dan time, disusul oleh age. serum_creatine memiliki kontribusi terbesar dalam pemisahan kelas, menunjukkan bahwa kadar kreatinin serum adalah faktor kunci dalam prediksi. time juga berperan penting, kemungkinan terkait dengan durasi atau waktu pengambilan data. age memiliki pengaruh moderat, menandakan bahwa usia turut berperan meskipun tidak sepenting dua fitur sebelumnya.



Analisis Hasil

Berdasarkan evaluasi model, **Logistic Regression** menunjukkan kinerja terbaik dengan Accuracy 0.8167 dan F1-Score 0.6452. Ini berarti bahwa model mampu memprediksi dengan baik dan memiliki keseimbangan yang baik antara Precision dan Recall, meskipun masih ada ruang untuk perbaikan.

Faktor risiko yang paling berpengaruh menurut model ini adalah time (periode tindak lanjut), ejection_fraction (fraksi ejeksi), serum_creatinine (kadar kreatinin serum), age (usia), dan sex (jenis kelamin). Faktor-faktor ini adalah indikator utama dalam menentukan kemungkinan kematian pasien akibat gagal jantung.





Kesimpulan

Model **Logistic Regression** mencapai akurasi 81,67% dan F1-Score 0,6452, menunjukkan performa yang solid dalam memprediksi risiko kematian pasien. Faktor paling berpengaruh adalah time, ejection_fraction, serum_creatinine, age, dan sex. Pasien dengan tindak lanjut singkat, fraksi ejeksi rendah, kadar kreatinin tinggi, dan usia tua cenderung berisiko lebih tinggi, sehingga perlu pemantauan ketat. Meski menjanjikan, model ini terbatas oleh ukuran data kecil dan potensi hubungan non-linear. Pengembangan lanjutan disarankan melalui perluasan data dan penambahan fitur klinis untuk mendukung sistem peringatan dini yang lebih akurat.



Terima Kasih

